



Universidad
Nacional
de Loja



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Matriz de Extracción de Artículos Científicos

Scientific Articles Extraction Matrix

Metodología de la Investigación en
Computación.

AUTOR:

Alejandro Padilla Espinoza

DOCENTE:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Alejandro Padilla Espinoza**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Apoyo en la estructuración y conversión del documento a formato LaTeX.
- Asistencia técnica para normalizar tablas, referencias y archivo BibTeX.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en asistencia lingüística, apoyo en organización documental y asistencia técnica de formato.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

Loja, Ecuador, 13 de mayo de 2026

Alejandro Padilla Espinoza

Autor

Índice General

Declaración de uso de IA Generativa	1
1 Matriz de extracción de artículos científicos	5
1.1 Información general del estudiante	5
1.2 Matriz de extracción	5
2 Síntesis y respuesta de investigación	12
2.1 Síntesis	12
2.2 Respuesta a la pregunta de investigación	12
2.3 Evidencias de la investigación	12
Referencias bibliográficas	13

Índice de Tablas

1.1	Matriz de extracción de artículos científicos sobre ASR, HMM y modelos derivados	6
-----	---	---

1. Matriz de extracción de artículos científicos

1.1. Información general del estudiante

Nombre del estudiante: Alejandro Padilla Espinoza

Técnica de IA: Modelos Ocultos de Markov (HMM) y evolución hacia modelos híbridos/profundos de reconocimiento de voz

Pregunta de investigación: ¿Cómo se utilizan los modelos ocultos de Markov y sus enfoques derivados en el reconocimiento de voz?

1.2. Matriz de extracción

Tabla 1.1: Matriz de extracción de artículos científicos sobre ASR, HMM y modelos derivados

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	M. Tian, “Design and Performance Optimization of Japanese Speech Recognition System Based on Deep Learning,” in Proceedings of the 2025 International Conference on Educational Technology and Artificial Intelligence, pp. 112-116, 2025., doi: 10.1145/3766557.3766577 [1]	2025-07-25	ACM DL	CNN + LSTM + atención	Optimizar el reconocimiento de voz japonés con mayor precisión y eficiencia.	Diseñar un sistema de reconocimiento japonés basado en aprendizaje profundo.	Arquitectura híbrida CNN-LSTM con mecanismo de atención y aumento de datos.	Tarea de voz japonesa; corpus no detallado en el resumen.	Reduce el WER en 15 % y mejora la tasa de tiempo real en 20 %.	El resumen no detalla tamaño del corpus ni condiciones de ruido.	Muestra cómo las arquitecturas profundas sustituyen o complementan el modelado secuencial clásico.
2	Q. Hu, K. Le, Z. Zhou, and Y. Tang, “LSTM Recurrent Neural Network Speech Recognition System Based on Genetic Algorithm Improved HMM,” in Proceedings of the 2025 6th International Conference on Computer Information and Big Data Applications, pp. 980-985, 2025., doi: 10.1145/3746709.3746875 [2]	2025-03-14	ACM DL	LSTM + algoritmo genético + HMM	Mejorar un sistema ASR basado en HMM ante variabilidad acústica.	Optimizar un HMM mediante algoritmo genético y red recurrente LSTM.	Preentrenamiento, normalización de características, GMM-HMM monoaural, refinamiento Tri1 y LDA/fMLLR.	Muestras de voz a 16 kHz; corpus experimental propio.	Reconocimiento promedio de 91.5 %, con máximo de 100 % y mínimo de 85 %.	Resultados dependientes del conjunto usado; no se reporta generalización amplia.	Conecta HMM con aprendizaje profundo recurrente para mejorar el reconocimiento secuencial.
3	L. Yang, J. Jin, M. Zhang, Y. He, B. Chen, and S. L. Wang, “Landmark Guided Visual Feature Extractor for Visual Speech Recognition with Limited Resource,” in Proceedings of the 4th International Workshop on Multimodal Human Understanding for the Web and Social Media, pp. 40-48, 2025., doi: 10.1145/3728481.3762165 [3]	2025-10-27	ACM DL	Extractor visual guiado por landmarks	El reconocimiento visual del habla falla con pocos datos y perturbaciones visuales.	Mejorar la extracción de rasgos visuales para reconocimiento de habla silenciosa.	Modelo guiado por puntos faciales/landmarks para extraer información visual relevante.	Videos de habla silenciosa con recursos limitados.	Mejora la representación visual para reconocimiento con recursos limitados.	Sensible a iluminación, textura de piel y calidad del video.	Amplía la PI hacia reconocimiento multimodal, donde la secuencia temporal sigue siendo central.

Continúa en la siguiente página

Continuación de la tabla anterior

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
4	Y. Yu, Q. Huang, M. Fan, Y. Liu, J. Ding, X. Wang, et al., “Conformer-based Tibetan Speech Recognition Algorithm,” in Proceedings of the 2024 10th International Conference on Communication and Information Processing, pp. 736-740, 2024., doi: 10.1145/3708657.3708775 [4]	2024-11-21	ACM DL	Conformer	Reconocimiento automático de voz tibetana en comunidades bilingües.	Construir un algoritmo ASR tibetano que capture rasgos locales y globales.	Modelo Conformer con convolución y autoatención.	Dataset de síntesis de dialecto tibetano.	WER reducido hasta 12.69 %.	Se requiere ampliar datos dialectales y validar en habla real diversa.	Evidencia la transición de HMM a modelos con atención para idiomas de bajos recursos.
5	H. Fang, and Z. Zhou, “Research on acoustic Model of Putian Dialect Speech Recognition Based on Deep Learning,” in Proceedings of the 2024 International Conference on Generative Artificial Intelligence and Information Security, pp. 94-99, 2024., doi: 10.1145/3665348.3665366 [5]	2024-05-10	ACM DL	DNN-HMM	Falta de corpus y modelos ASR para el dialecto Putian.	Reconocer palabras aisladas del dialecto Putian con modelos acústicos profundos.	Modelos de fonema, trifenema, LDA, MLLT, SAT y DNN-HMM con mapeo fonema-dialecto-mandarín.	8000 palabras aisladas del dialecto Putian.	DNN-HMM-2 obtiene WER de 20.56 % y mejora el CER cerca de 3 %.	Corpus pequeño y limitado a palabras aisladas.	Demuestra la utilidad del DNN-HMM en dialectos con escasez de datos.
6	H. M. S. Naing, and W. P. Pa, “A Large Vocabulary End-to-End Myanmar Automatic Speech Recognition,” in ACM Multimedia Asia Workshops, pp. 1-5, 2023., doi: 10.1145/3611380.3628559 [6]	2023-12-06	ACM DL	Transformer / Conformer / LSTM	Reconocimiento de vocabulario amplio para idioma myanmar.	Evaluar modelos híbridos y end-to-end para ASR myanmar.	Comparación de LSTM híbrido y modelos end-to-end Transformer/Conformer.	Corpus UCSY-Myan-ASR de 82 horas.	Transformer: SER 9.6 % y CER 7.3 %; Conformer: SER 10.6 % y CER 6.9 %.	Desempeño varía por dominio conversacional/noticias.	Sirve para comparar HMM híbridos frente a enfoques end-to-end modernos.
7	L. Han, “Deep Neural Network-based Mixed Speech Recognition Technology for Chinese and English,” ACM Transactions on Asian and Low-Resource Language Information Processing, 2023., doi: 10.1145/3616373 [7]	2023-08-17	ACM DL	DNN + atención + CTC + Transformer	Reconocimiento mixto chino-inglés en interacción humano-computador.	Construir un modelo híbrido para habla monolingüe y mixta.	Fusión de atención y pérdida CTC dentro de un enfoque end-to-end/Transformer.	Datasets de habla china, inglesa y chino-inglés mixta.	Alcanza 81.2 % de precisión y 100 unidades/minuto en habla mixta.	El resultado depende del conjunto chino-inglés usado.	Muestra cómo los modelos secuenciales evolucionan desde HMM a CTC/Transformer.

Continúa en la siguiente página

Continuación de la tabla anterior

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
8	M. Daouad, and E. W. Dadi, “Amazigh Speech Recognition Using 1D CNN,”, in Proceedings of the 6th International Conference on Networking, Intelligent Systems & Security, pp. 1-6, 2023., doi: 10.1145/3607720.3607760 [8]	2023-05-24	ACM DL	CNN 1D	Reconocimiento de palabras aisladas en lengua amazigh.	Reconocer 18 palabras amazigh mediante aprendizaje profundo.	Extracción de espectrogramas y clasificación con CNN 1D de ocho capas.	2000 audios de hablantes nativos amazigh del Rif marroquí.	Precisión de 94.77 %.	Limitado a 18 palabras aisladas y a una región lingüística.	Complementa la PI mostrando alternativas profundas para ASR de bajo recurso.
9	Z. CantiaBELA, H. F. Pardede, V. Zilvan, W. Sulandari, R. S. Yuwana, A. A. Supianto, et al., “Deep Learning for Robust Speech Command Recognition Using Convolutional Neural Networks (CNN),”, in Proceedings of the 2022 International Conference on Computer, Control, Informatics and Its Applications, pp. 101-105, 2022., doi: 10.1145/3575882.3575902 [9]	2022-11-22	ACM DL	CNN para comandos de voz	El reconocimiento de comandos se degrada en ambientes ruidosos.	Diseñar CNN robustas para reconocer comandos en condiciones limpias y con ruido.	CNN con distintas profundidades, early stopping y optimizadores Adam/SGD.	Comandos de voz en condiciones limpias y ruidosas.	CNN: 90.64 % en limpio; en ruido, más capas mejoran robustez hasta 87.59 %.	Se centra en comandos, no en habla continua.	Aporta evidencia sobre robustez al ruido, una limitación clásica de HMM.
10	Z. Zhao, N. Yang, and S. Yang, “Research on Noise Processing Methods of Speech Recognition in Noisy Environment,”, in Proceedings of the 2022 6th International Conference on Electronic Information Technology and Computer Engineering, pp. 1504-1510, 2022., doi: 10.1145/3573428.3573693 [10]	2022-10-21	ACM DL	Procesamiento de ruido para ASR	El ruido ambiental reduce la precisión del reconocimiento.	Analizar métodos de procesamiento de ruido en sistemas ASR.	Evaluación de técnicas de tratamiento de ruido aplicadas al reconocimiento.	Entornos ruidosos; corpus no especificado en metadatos.	Identifica estrategias para mejorar reconocimiento bajo ruido.	Metadatos disponibles no reportan métricas detalladas.	Apoya la discusión de preprocesamiento acústico antes del modelado secuencial.

Continúa en la siguiente página

Continuación de la tabla anterior

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
11	Y. Song, R. Lian, Y. Chen, D. Jiang, X. Zhao, C. Tan, et al., “A Platform for Deploying the TFE Ecosystem of Automatic Speech Recognition,” in Proceedings of the 30th ACM International Conference on Multimedia, pp. 6952-6954, 2022., doi: 10.1145/3503161.3547731 [11]	2022-10-10	ACM DL	Plataforma TFE para ASR	Dificultad para desplegar ecosistemas ASR completos.	Proponer una plataforma para desplegar el ecosistema TFE de reconocimiento automático.	Diseño de plataforma y componentes de despliegue para ASR.	Contexto de despliegue de ecosistema ASR.	Facilita integración y despliegue de componentes ASR.	Más orientado a plataforma que a evaluación algorítmica de precisión.	Relaciona la técnica con implementación real de sistemas ASR.
12	D. Jiang, C. Tan, J. Peng, C. Chen, X. Wu, W. Zhao, et al., “A GDPR-compliant Ecosystem for Speech Recognition with Transfer, Federated, and Evolutionary Learning,” ACM Transactions on Intelligent Systems and Technology, vol. 12, no. 3, pp. 1-19, 2021., doi: 10.1145/3447687 [12]	2021-06-30	ACM DL	Transfer learning + federated learning + evolutionary learning	Cumplir GDPR sin centralizar datos de voz sensibles.	Diseñar un ecosistema ASR compatible con privacidad.	Aprendizaje transferido, federado y evolutivo para entrenamiento distribuido.	Escenario de datos distribuidos y privados de voz.	Propone una arquitectura de entrenamiento colaborativo preservando privacidad.	Mayor complejidad de coordinación y evaluación distribuida.	Aporta dimensión ética/legal al uso de datos de voz para ASR.
13	J. Novoa, R. Mahu, J. Wuth, J. P. Escudero, J. Fredes, and N. B. Yoma, “Automatic Speech Recognition for Indoor HRI Scenarios,” ACM Transactions on Human-Robot Interaction, vol. 10, no. 2, pp. 1-30, 2021., doi: 10.1145/3442629 [13]	2021-06-30	ACM DL	DNN-HMM + beamforming	Reconocimiento indoor HRI afectado por movimiento, reverberación y ruido.	Crear ASR independiente para interacción humano-robot en interiores.	Entrenamiento con respuestas de canal, ruido y beamforming con posición de usuario.	Grabaciones con robot real y condiciones de movimiento.	WER al menos 19 % y 34 % menor que APIs públicas en pruebas con parlante y humanos.	Escenario HRI específico; requiere modelado acústico del entorno.	Caso directo de DNN-HMM aplicado a robótica y ruido real.
14	J. Novoa, J. Wuth, J. P. Escudero, J. Fredes, R. Mahu, and N. B. Yoma, “DNN-HMM based Automatic Speech Recognition for HRI Scenarios,” in Proceedings of the 2018 ACM/IEEE International Conference on Human-Robot Interaction, pp. 150-159, 2018., doi: 10.1145/3171221.3171280 [14]	2018-02-26	ACM DL	DNN-HMM	ASR para HRI con reverberación, movimiento y fuentes variables.	Integrar representación del entorno y estados del robot/usuario al reconocimiento.	DNN-HMM entrenado con habla limpia combinada con respuestas acústicas y ruido.	Testbed HRI con robot PR2 y Kinect.	WER al menos 26 % y 38 % menor que APIs públicas según modalidad.	Dependiente del entorno robótico y de datos acústicos simulados/medidos.	Evidencia aplicación temprana de DNN-HMM en escenarios reales de HRI.

Continúa en la siguiente página

Continuación de la tabla anterior

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
15	B. C. Yan, S. H. Liu, and B. Chen, "Modulation spectrum augmentation for robust speech recognition," in Proceedings of the 1st International Conference on Advanced Information Science and System, pp. 1-6, 2019., doi: 10.1145/3373477.3373695 [15]	2019-11-15	ACM DL	Aumento por espectro de modulación	Robustez limitada del ASR ante condiciones acústicas variables.	Aumentar datos de habla mediante deformaciones en dominios de modulación.	Perturbación en onda y warping en representaciones cepstrales/modulación.	Aurora-4 con sistema ASR DNN-HMM.	WERR de 17.6 % en entrenamiento limpio y 0.69 % en multi-condición; dos etapas hasta 1.13 %.	Ganancia menor en configuración multi-condición.	Aporta técnica de data augmentation para reforzar modelos tipo HMM/DNN-HMM.
16	R. Prabhavalkar, T. Hori, T. N. Sainath, R. Schlüter, and S. Watanabe, "End-to-End Speech Recognition: A Survey," IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 32, pp. 325-351, 2023., doi: 10.1109/TASLP.2023.3328283 [16]	2023-10-30	IEEE Xplore	ASR end-to-end	Comprender la transición desde HMM clásico a modelos E2E.	Revisar taxonomía, entrenamiento, decodificación y despliegue de ASR end-to-end.	Revisión sistemática/narrativa de arquitecturas y componentes E2E.	Literatura y sistemas ASR recientes.	Sintetiza avances que redujeron WER y dependencia de componentes clásicos.	Artículo de revisión; no propone un experimento único.	Marco teórico para contrastar HMM con enfoques modernos.
17	S. Ghorbani, and J. H. Hansen, "Domain Expansion for End-to-End Speech Recognition: Applications for Accent/Dialect Speech," IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 31, pp. 762-774, 2022., doi: 10.1109/TASLP.2022.3233238 [17]	2022-12-30	IEEE Xplore	Expansión de dominio + SKLD + model averaging	Adaptar ASR secuencialmente sin olvidar dominios/acento previos.	Mitigar catastrophic forgetting al expandir dominios de acento/dialecto.	Regularización SKLD y model averaging para escenarios con y sin datos previos.	Adaptación de inglés nativo a diferentes acentos del inglés.	SKLD-MA mejora el compromiso entre dominios y reduce pérdida en dominios previos.	Centrado en acentos del inglés; depende de disponibilidad de datos previos/nuevos.	Conecta ASR moderno con adaptación continua, reto también presente en HMM.
18	X. Sun, Q. Yang, S. Liu, and X. Yuan, "Improving Low-Resource Speech Recognition Based on Improved NN-HMM Structures," IEEE Access, vol. 8, pp. 73005-73014, 2020., doi: 10.1109/ACCESS.2020.2988365 [18]	2020-04-16	IEEE Xplore	NN-HMM mejorado	Reconocimiento de voz en escenarios de bajo recurso.	Mejorar estructuras NN-HMM para aumentar precisión con datos limitados.	Ajustes al modelo híbrido NN-HMM para aprovechar mejor características acústicas.	Contexto de ASR de bajo recurso.	Reporta mejora del reconocimiento con estructuras NN-HMM optimizadas.	Fecha exacta completada por DOI; requiere PDF IEEE para validación final.	Referencia central para la PI porque aborda directamente HMM mejorado en ASR.

Continúa en la siguiente página

Continuación de la tabla anterior

#	Referencia (IEEE)	Año / fecha	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
19	K. El Manaa, N. Laaidi, Y. Abouch, and H. Satori, “Robust Real-Time Arabic Speech Recognition for AAVs in Adverse Acoustic Conditions Using Lightweight CNNs,” IEEE Access, vol. 13, pp. 179803-179816, 2025., doi: 10.1109/ACCESS.2025.3622024 [19]	2025-10-15	IEEE Xplore	CNN ligera + squeeze-and-excitation	Reconocimiento árabe en AAV/UAV bajo condiciones acústicas adversas.	Construir ASR árabe robusto y en tiempo real para comandos de drones.	CNN ligera con bloques de atención SE y entrenamiento con ruido inyectado.	8800 comandos de drones en árabe estándar moderno.	Arquitectura eficiente y robusta ante ruido para operación en tiempo real.	Dominio restringido a comandos de drones; fecha exacta requiere verificación PDF IEEE.	Muestra aplicaciones actuales de ASR robusto en bajo recurso y ruido real.
20	J. W. Kim, H. Yoon, and H. Y. Jung, “Linguistic-Coupled Age-to-Age Voice Translation to Improve Speech Recognition Performance in Real Environments,” IEEE Access, vol. 9, pp. 136476-136486, 2021., doi: 10.1109/ACCESS.2021.3115608 [20]	2021-09-24	IEEE Xplore	Voice conversion + Transformer	Bajo rendimiento de ASR comercial en voces de adultos mayores.	Traducir características de edad para mejorar reconocimiento sin modificar el ASR.	Modelo age-to-age voice translation con clustering fonológico no supervisado.	VOTE400, AIHub y dataset adulto de referencia.	Mejora el reconocimiento de voz de adultos mayores frente a enfoques base.	Requiere modelar diferencias de tempo y alineación entre grupos etarios.	Aporta adaptación de entrada acústica como alternativa a cambiar el reconocedor.
21	I. Yasin, V. Drga, F. Liu, A. Demosthenous, and R. Meddis, “Optimizing Speech Recognition Using a Computational Model of Human Hearing: Effect of Noise Type and Efferent Time Constants,” IEEE Access, vol. 8, pp. 56711-56719, 2020., doi: 10.1109/ACCESS.2020.2981885 [21]	2020-03-23	IEEE Xplore	Modelo computacional auditivo + ASR	Comprender efecto del ruido y constantes eferentes en reconocimiento.	Evaluar un front-end auditivo inspirado en el sistema olivococlear.	Modelo auditivo con procesamiento eferente como entrada a ASR.	Señales con ruido modulado y no modulado en distintos SNR.	Mayor mejora alrededor de 10 dB SNR; efectos dependen del tipo de ruido y constante temporal.	Modelo fisiológico específico; no es un sistema ASR general completo.	Explica cómo el preprocesamiento inspirado en audición puede mejorar ASR.
22	V. V. S, and C. S, “Investigation of DNN-HMM and Lattice Free Maximum Mutual Information Approaches for Impaired Speech Recognition,” IEEE Access, vol. 9, pp. 168840-168849, 2021., doi: 10.1109/ACCESS.2021.3129847 [22]	2021-11-22	IEEE Xplore	DNN-HMM + LF-MMI	Reconocer habla deteriorada por trastornos neurológicos.	Comparar DNN-HMM y LF-MMI para reconocimiento de habla impedida en tamil.	Entrenamiento/evaluación con palabras acústicamente similares y corpus de 50 palabras.	Corpus de habla impedida en tamil con niveles de inteligibilidad.	Compara enfoques para mejorar interacción de personas con habla afectada.	Dominio específico y fecha exacta requiere verificación PDF IEEE.	Caso relevante de HMM/DNN-HMM en accesibilidad y habla no estándar.

2. Síntesis y respuesta de investigación

2.1. Síntesis

En los trabajos vinculados directamente con HMM, el aporte principal está en la robustez probabilística y la adaptación a condiciones complejas: ruido, reverberación, acentos, bajo recurso, habla deteriorada e interacción humano-robot. Las investigaciones más recientes amplían este enfoque mediante aprendizaje profundo, aumento de datos, aprendizaje federado y adaptación de dominio, lo que evidencia que el reconocimiento de voz moderno conserva problemas clásicos del HMM, pero los aborda con técnicas más flexibles.

La matriz también evidencia un patrón recurrente: mayor precisión suele implicar mayor complejidad computacional, más datos y más dependencia del dominio. Por eso, para una investigación sobre HMM en reconocimiento de voz, no basta con describir el modelo clásico; es necesario explicar su papel histórico y su transformación en sistemas híbridos o comparativos frente a modelos end-to-end.

Respuesta a la pregunta de investigación

2.2. Respuesta a la pregunta de investigación

Evidencias de la investigación

2.3. Evidencias de la investigación

- Metadatos importados y validados desde Mendeley mediante archivo RIS: metadata_limpia_docente_fechas_completas.ris.
- Las fechas completas fueron conservadas en la matriz como Año / fecha para cumplir el requisito docente.
- Referencias IEEE utilizadas

Referencias bibliográficas

- [1] M. Tian, “Design and performance optimization of japanese speech recognition system based on deep learning,” in *Proceedings of the 2025 International Conference on Educational Technology and Artificial Intelligence*, ser. ETAIC 2025. New York, NY, USA: Association for Computing Machinery, July 2025, pp. 112–116. [Online]. Available: <https://doi.org/10.1145/3766557.3766577>
- [2] Q. Hu, K. Le, Z. Zhou, and Y. Tang, “Lstm recurrent neural network speech recognition system based on genetic algorithm improved hmm,” in *Proceedings of the 2025 6th International Conference on Computer Information and Big Data Applications*, ser. CIBDA 2025. New York, NY, USA: Association for Computing Machinery, March 2025, pp. 980–985. [Online]. Available: <https://doi.org/10.1145/3746709.3746875>
- [3] L. Yang, J. Jin, M. Zhang, Y. He, B. Chen, and S.-L. Wang, “Landmark guided visual feature extractor for visual speech recognition with limited resource,” in *Proceedings of the 4th International Workshop on Multimodal Human Understanding for the Web and Social Media*. New York, NY, USA: Association for Computing Machinery, October 2025, pp. 40–48. [Online]. Available: <https://doi.org/10.1145/3728481.3762165>
- [4] Y. Yu, Q. Huang, M. Fan, Y. Liu, J. Ding, X. Wang, Z. Zhang, L. Li, N. Qun, D. Renzeng, T. Karma, and F. Ekong, “Conformer-based tibetan speech recognition algorithm,” in *Proceedings of the 2024 10th International Conference on Communication and Information Processing*, ser. ICCIP 2024. New York, NY, USA: Association for Computing Machinery, November 2024, pp. 736–740. [Online]. Available: <https://doi.org/10.1145/3708657.3708775>
- [5] H. Fang and Z. Zhou, “Research on acoustic model of putian dialect speech recognition based on deep learning,” in *Proceedings of the 2024 International Conference on Generative Artificial Intelligence and Information Security*, ser. GAIIS 2024. New York, NY, USA: Association for Computing Machinery, May 2024, pp. 94–99. [Online]. Available: <https://doi.org/10.1145/3665348.3665366>
- [6] H. M. S. Naing and W. P. Pa, “A large vocabulary end-to-end myanmar automatic speech recognition,” in *ACM Multimedia Asia Workshops*, ser. MMAsia ’23. New York, NY, USA: Association for Computing Machinery, December 2023, pp. 1–5. [Online]. Available: <https://doi.org/10.1145/3611380.3628559>

- [7] L. Han, “Deep neural network-based mixed speech recognition technology for chinese and english,” *ACM Transactions on Asian and Low-Resource Language Information Processing*, August 2023. [Online]. Available: <https://doi.org/10.1145/3616373>
- [8] M. Daouad and E. W. Dadi, “Amazigh speech recognition using 1d cnn,” in *Proceedings of the 6th International Conference on Networking, Intelligent Systems & Security*, ser. NISS 2023. New York, NY, USA: Association for Computing Machinery, May 2023, pp. 1–6. [Online]. Available: <https://doi.org/10.1145/3607720.3607760>
- [9] Z. Cantiabela, H. F. Pardede, V. Zilvan, W. Sulandari, R. S. Yuwana, A. A. Supianto, and D. Krisnandi, “Deep learning for robust speech command recognition using convolutional neural networks (cnn),” in *Proceedings of the 2022 International Conference on Computer, Control, Informatics and Its Applications*, ser. IC3INA 2022. New York, NY, USA: Association for Computing Machinery, November 2022, pp. 101–105. [Online]. Available: <https://doi.org/10.1145/3575882.3575902>
- [10] Z. Zhao, N. Yang, and S. Yang, “Research on noise processing methods of speech recognition in noisy environment,” in *Proceedings of the 2022 6th International Conference on Electronic Information Technology and Computer Engineering*, ser. EITCE 2022. New York, NY, USA: Association for Computing Machinery, October 2022, pp. 1504–1510. [Online]. Available: <https://doi.org/10.1145/3573428.3573693>
- [11] Y. Song, R. Lian, Y. Chen, D. Jiang, X. Zhao, C. Tan, Q. Xu, and R. C.-W. Wong, “A platform for deploying the tfe ecosystem of automatic speech recognition,” in *Proceedings of the 30th ACM International Conference on Multimedia*, ser. MM ’22. New York, NY, USA: Association for Computing Machinery, October 2022, pp. 6952–6954. [Online]. Available: <https://doi.org/10.1145/3503161.3547731>
- [12] D. Jiang, C. Tan, J. Peng, C. Chen, X. Wu, W. Zhao, Y. Song, Y. Tong, C. Liu, Q. Xu, Q. Yang, and L. Deng, “A gdpr-compliant ecosystem for speech recognition with transfer, federated, and evolutionary learning,” *ACM Transactions on Intelligent Systems and Technology*, vol. 12, no. 3, pp. 1–19, June 2021. [Online]. Available: <https://doi.org/10.1145/3447687>
- [13] J. Novoa, R. Mahu, J. Wuth, J. P. Escudero, J. Fredes, and N. B. Yoma, “Automatic speech recognition for indoor hri scenarios,” *ACM Transactions on*

- Human-Robot Interaction*, vol. 10, no. 2, pp. 1–30, June 2021. [Online]. Available: <https://doi.org/10.1145/3442629>
- [14] J. Novoa, J. Wuth, J. P. Escudero, J. Fredes, R. Mahu, and N. B. Yoma, “Dnn-hmm based automatic speech recognition for hri scenarios,” in *Proceedings of the 2018 ACM/IEEE International Conference on Human-Robot Interaction*, ser. HRI ’18. New York, NY, USA: Association for Computing Machinery, February 2018, pp. 150–159. [Online]. Available: <https://doi.org/10.1145/3171221.3171280>
 - [15] B.-C. Yan, S.-H. Liu, and B. Chen, “Modulation spectrum augmentation for robust speech recognition,” in *Proceedings of the 1st International Conference on Advanced Information Science and System*, ser. AISS 2019. New York, NY, USA: Association for Computing Machinery, November 2019, pp. 1–6. [Online]. Available: <https://doi.org/10.1145/3373477.3373695>
 - [16] R. Prabhavalkar, T. Hori, T. N. Sainath, R. Schlüter, and S. Watanabe, “End-to-end speech recognition: A survey,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 32, pp. 325–351, October 2023. [Online]. Available: <https://doi.org/10.1109/TASLP.2023.3328283>
 - [17] S. Ghorbani and J. H. Hansen, “Domain expansion for end-to-end speech recognition: Applications for accent/dialect speech,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 762–774, December 2022. [Online]. Available: <https://doi.org/10.1109/TASLP.2022.3233238>
 - [18] X. Sun, Q. Yang, S. Liu, and X. Yuan, “Improving low-resource speech recognition based on improved nn-hmm structures,” *IEEE Access*, vol. 8, pp. 73 005–73 014, April 2020. [Online]. Available: <https://doi.org/10.1109/ACCESS.2020.2988365>
 - [19] K. El Manaa, N. Laaidi, Y. Abouch, and H. Satori, “Robust real-time arabic speech recognition for aavs in adverse acoustic conditions using lightweight cnns,” *IEEE Access*, vol. 13, pp. 179 803–179 816, October 2025. [Online]. Available: <https://doi.org/10.1109/ACCESS.2025.3622024>
 - [20] J.-W. Kim, H. Yoon, and H.-Y. Jung, “Linguistic-coupled age-to-age voice translation to improve speech recognition performance in real environments,” *IEEE Access*, vol. 9, pp. 136 476–136 486, September 2021. [Online]. Available: <https://doi.org/10.1109/ACCESS.2021.3115608>
 - [21] I. Yasin, V. Drga, F. Liu, A. Demosthenous, and R. Meddis, “Optimizing speech recognition using a computational model of human hearing: Effect of noise type

and efferent time constants,” *IEEE Access*, vol. 8, pp. 56 711–56 719, March 2020. [Online]. Available: <https://doi.org/10.1109/ACCESS.2020.2981885>

- [22] V. V. S and C. S, “Investigation of dnn-hmm and lattice free maximum mutual information approaches for impaired speech recognition,” *IEEE Access*, vol. 9, pp. 168 840–168 849, November 2021. [Online]. Available: <https://doi.org/10.1109/ACCESS.2021.3129847>